

Команда 3 Лося́

Speaker Recognition in the Wild





overview

- 01** Обзор датасетов
- 02** Наши эксперименты
- 03** Fine-tuning
- 04** Итоги

Данные... Какие данные?

Train

Источник: предоставленный организаторами
(подмножество VoxBlink2)

Файлов: 673 277

Общая длительность: 1 457.77 часов

Спикеров: 11 053

Формат файлов: flac mono 16kHz

APPROVED

Данные... Какие данные?

Test public

Источник: предоставленный организаторами

Файлов: 134 697

Общая длительность: 344.55 часов

Формат файлов: flac mono 16kHz

APPROVED

Данные... Какие данные?

MSDWILD

Файлов: 3143

Общая длительность: ~84 часа

Спикеров: неизвестно

Формат файлов: один файл → RTTM-разметка

Итог: невозможно использовать для наших задач



Данные... Какие данные?

VOICES

Файлов: ~40 000

Общая длительность: ~3 800 часов

Спикеров: 300

Формат файлов: flac mono 16kHz

Итог: 450 ГБ, не влез на сервер



Данные... Какие данные?

TidyVoice

Файлов: ~2 500 000

Общая длительность: 8 138 часов

Спикеров: ~212 000

Формат файлов: flac mono 16kHz

Особенность: лицензия запрещает использование этого сета для задач идентификации спикеров (1:N поиск)



Данные... Какие данные?

AISHELL-4

Файлов: 211

Общая длительность: 120 часов

Спикеров: неизвестно

Формат файлов: flac, 8 каналов, 16 кГц, TextGrid-разметка

Итог: невозможно использовать для наших задач



Данные... Какие данные?

LibriSpeech train-other-500

Файлов: 148 688

Общая длительность: 500 часов


Спикеров: 1 166

Формат: flac mono 16kHz

Особенность: не удалось загрузить из-за блокировки РКН



Наш конструктор пайплайнов




- Загрузка аудио
- батчинг
- препроцессинг

- Эмбеддинг из аудио

- Загрузка эмбеддингов в хранилище
- Поиск k ближайших
- Формирует submission

Лучшее сочетание точности и скорости



- Препроцессинг с FireRedVad
- энкодер IDRnD/redimnet_b6_vox2_ft_lm
- Постпроцессинг с AS-Norm
- Оптимизация за счёт компиляции энкодера и распараллеливания загрузки аудио на вход

Результат на Public test: 0.6347


Общее время пайплайна: 6980.11 с.

Сделать лучше возможно!

Дообучение Энкодера на Train датасете от организаторв!

Этап	Эпох	Crop	Margin	Batch	Аугментация
Head warmup	3	3 сек	0	32	
Full finetune	7	4 сек	0.2	16	
Large margin	8	6 сек	0.5	8	

Результаты после обучения



Результат на Public test: 0.6757

Общее время пайплайна: 6980.11 с.

Дообучение позволило повысить точность на public test на **0.041!**

Итоги и дальнейшие направления развития

Что было сделано:

- Собраны и проанализированы данные
- Подобраны энкодеры и методы пред- и пост-обработки
- Произведён fine tuning модели энкодера


Исследования, достойные упоминания:

- Не нейросетевой подход к реализации энкодера “GMM-UBM”
- Ансамблирование энкодеров
- Аугментации во время инференса

Итоги и дальнейшие направления развития


Дальнейшее развитие:

- Завершение обучения модели энкодера
- Quality-aware scoring
- Multi-system fusion
- Sub-center ArcFace
- Расширенные аугментации
- Embedding post-processing

A close-up, slightly angled view of a computer keyboard. The keys are dark grey or black. Several keys feature blue, raised, 3D icons. Visible icons include a square with a diagonal line (prohibited), a magnifying glass (search), a padlock (lock), and a star. The text "Спасибо за внимание!" is overlaid in white, bold, sans-serif font across the center of the image.

**Спасибо за
внимание!**

Отправная точка




Результат на Public test: 0.0838 ●

Время векторизации: 1416.38 с.

Время поиска к ближайших векторов: 100.05 с.

Общее время: 1516.43 с. ●

Проверка энкодера `nvidia/speakerverification_en_titanet_large`




Результат на Public test: 0.1968 

Время векторизации: —

Время поиска к ближайших векторов: —

Общее время: —

Проверка энкодера speechbrain/spkrec-ecapa-voxceleb



Результат на Public test: 0.5065 🌲


Время векторизации: 3004.14 с.

Время поиска к ближайших векторов: 87.15 с.

Общее время: 3091.30 с. 🚩

Проверка энкодера

Wespeaker/wespeaker-voxceleb-resnet293-LM



Результат на Public test: 0.5356 🌲


Время векторизации: 12951.62 с.

Время поиска к ближайших векторов: 110.89 с.

Общее время: 13062.51 с. 🚩

Проверка энкодера

Wespeaker/wespeaker-voxceleb-resnet34-LM




Результат на Public test: 0.5043 🌲

Время векторизации: 2176.81 с.

Время поиска к ближайшим векторов: 117.41 с.

Общее время: 2294.21 с. ▼

Проверка энкодера microsoft/wavlm-base-sv




Результат на Public test: 0.0547 ▼

Время векторизации: 6237.57 с.

Время поиска к ближайших векторов: 218.30 с.

Общее время: 6455.87 с. ▼

Проверка энкодера microsoft/wavlm-base-plus-sv




Результат на Public test: 0.0976 ▲

Время векторизации: 5995.82 с.

Время поиска к ближайших векторов: 209.63 с.

Общее время: 6205.45 с. ▼

Проверка энкодера IDRnD/redimnet_b6_vox2_ft_lm




Результат на Public test: 0.5840 🌲

Время векторизации: 7959.82 с.

Время поиска к ближайшим векторов: 88.44 с.

Общее время: 8048.27 с. 📉

Проверка энкодера damo/speech_campplus_sv_zh-cn_16k-common



Результат на Public test: 0.2774 


Время векторизации: 7814.16 с.

Время поиска к ближайшим векторов: 113.76 с.

Общее время: 7927.91 с. 

Проверка энкодера

iic/speech_eres2netv2_sv_zh-cn_16k-common




Результат на Public test: 0.2757 📈

Время векторизации: 10332.98 с.

Время поиска к ближайших векторов: 177.40 с.

Общее время: 10510.38 с. 📉

Проверка препроцессинга с FireRedVad




Результат на Public test: 0.0911 ▲

Общее время пайплайна: 5109.37 с. ▼

По сравнению с энкодером без FireRedVad

Проверка препроцессинга с FireRedVad




Результат на Public test: 0.6074 ▲

Общее время пайплайна: 14939.87 с. ▼

По сравнению с энкодером без FireRedVad

Проверка постпроцессинга с AS-Norm




Результат на Public test: 0.0895 ▲

Общее время пайплайна: 1521.01 с. ▼

По сравнению с энкодером без AS-Norm

Проверка постпроцессинга с AS-Norm




Результат на Public test: 0.6132 ▲

Общее время пайплайна: 8444.67 с. ▼

По сравнению с энкодером без AS-Norm

Проверка с FireRedVad + AS-Norm

+ torch.compile optimization



Результат на Public test: 0.6347 ▲

Общее время пайплайна: 6980.11 с. ▲

По сравнению с энкодером без FireRedVad и AS-Norm

Vad (Voice activity detection)

Проблема в том, что мы берём на вход энкодеру первые 6 секунд аудио. Там может не быть речи спикера, или её может быть недостаточно для формирования корректных эмбеддингов. VAD умеет извлекать из аудио сегменты с речью.

Наше решение:

- С помощью Vad извлекаем сегменты с речью из входного аудио и объединяем их.
- Из полученного аудио с речью первые 6 секунд поступают в энкодер.
- Сравнивали результаты для FireRedVad и FunASRVad.

Результат: повышение качества эмбеддингов, что доказывает увеличенная оценка на test public. FireRedVad оказался быстрее, поэтому дальше будем использовать именно его.

AS-Norm (Adaptive Symmetric Normalization)

Проблема в том, что эмбединги разных спикеров в шумной среде могут быть аномально близки. Это приводит к снижению релевантности поиска в векторном пространстве. **AS-Norm** выравнивает оценки относительно фонового распределения, подавляя ложную близость.

Наше решение:

- Фиксированный `n_candidates` отрезал полезных кандидатов при глубоком поиске.
- Мы привязали `n_candidates` к `top_k`: чем больше `top_k`, тем шире поиск.
- Система адаптивно масштабирует проверяемое множество.
- Снизили влияние «прилипчивых» векторов без потери качества на малых `top_k`.

Результат: повышение точности идентификации во всех диапазонах `top_k`. Поэтому мы точно будем использовать AS-Norm в нашем пайплайне.