

Криптонит.Тембр

Распознавание диктора по голосу в условиях шумов и доменных искажений

Отчёт по экспериментам

Команда «Три Лося»

19 апреля 2026

Содержание

1 Введение и постановка задачи	2
1.1 Задача	2
1.2 Метрика: Precision@K	2
1.3 Формат submission	2
2 Данные	2
2.1 Обучающий датасет (train)	2
2.2 Тестовый датасет (test_public)	3
3 Baseline организаторов	3
4 Модульный пайплайн	3
5 Эксперименты с энкодерами	4
5.1 Выводы по энкодерам	4
6 Предобработка: Voice Activity Detection	4
6.1 Гипотеза	4
6.2 FireRedVAD	4
7 Постобработка: Adaptive Score Normalization	5
7.1 Гипотеза	5
7.2 Реализация AS-Norm	5
8 Комбинация VAD + AS-Norm	5
8.1 Расширение пула кандидатов AS-Norm	6

9 Инженерные оптимизации	6
9.1 Префетч данных	6
9.2 Компиляция модели	6
10 Fine-tuning ReDimNet-b6	7
10.1 Мотивация	7
10.2 Loss: AAM-Softmax (ArcFace)	7
10.3 3-стадийная стратегия	7
10.4 Аугментации (Stage 1–2)	7
10.5 Инфраструктура обучения	7
10.6 Промежуточные результаты обучения	8
10.7 Результаты на test_public	8
11 Итоговое решение	9
11.1 Сводная таблица прогресса	9
12 Выводы	9
13 Дальнейшее развитие	10
13.1 Завершение обучения	10
13.2 Quality-aware scoring	10
13.3 Multi-system fusion	10
13.4 Sub-center ArcFace	10
13.5 Расширенные аугментации	11
13.6 Embedding post-processing	11
14 Воспроизводимость	11
14.1 Зависимости	11
14.2 Модели	11

1 Введение и постановка задачи

1.1 Задача

Разработать модель/пайплайн распознавания диктора по голосу, устойчивый к шумам, реверберации, записи с большого расстояния и искажениям канала связи. Для каждой тестовой аудиозаписи (FLAC) решение строит эмбединг фиксированной размерности, а затем формирует список K наиболее похожих записей из тестового набора (поиск ближайших соседей).

1.2 Метрика: Precision@K

Для каждой тестовой записи проверяющая система сравнивает `speaker_id` с `speaker_id` найденных ближайших соседей:

$$\text{Precision@}K = \frac{1}{N} \sum_{i=1}^N \frac{|\{\text{соседей записи } i \text{ с тем же спикером}\}|}{K}$$

Self-match исключается. $K = 10$ для итогового счёта. Диапазон: $[0, 1]$, больше — лучше.

1.3 Формат submission

CSV с колонками `filepath` и `neighbours`. Для каждой записи указываются 10 индексов ближайших соседей через запятую.

2 Данные

2.1 Обучающий датасет (train)

Характеристика	Значение
Файлов	673 277
Общая длительность	1 457.77 часов
Спикеров	11 053
Формат	FLAC, mono, 16 kHz

Предоставленный датасет — подмножество ($\approx 10\%$) оригинального VoxBlink2, из которого оставлены только аудио и идентификаторы спикеров.

Особенности VoxBlink2:

- **In the wild:** видео обычных людей в разных условиях (подкасты, стримы, лайфстайл-блоги);
- **Робастность:** модели, обученные на таких данных, устойчивы к фоновому шуму и изменениям голоса;

- **Многоязычность:** оригинальный датасет охватывает ≈ 18 языков.

Неопределённости: неизвестно, какая именно часть VoxBlink2 предоставлена, представлены ли все языки и какова языковая композиция.

2.2 Тестовый датасет (test_public)

Характеристика	Значение
Файлов	134 697
Общая длительность	344.55 часов
Формат	FLAC, mono, 16 kHz

3 Baseline организаторов

Организаторы предоставили базовое решение на основе ECAPA-TDNN, экспортированное в ONNX (baseline.onnx). Ключевые особенности:

- На вход подаются **случайные** 6 секунд аудио;
- Эмбединги нормализуются (L2);
- Поиск ближайших соседей через cosine similarity.

Результат baseline: **Precision@10 = 0.0837**.

Наблюдение: замена случайного кропа на первые 6 секунд практически не влияет на результат (0.0838), что указывает на то, что основное ограничение — качество самого энкодера, а не способ нарезки аудио.

4 Модульный пайплайн

Для систематизации экспериментов был разработан модульный пайплайн с заменяемыми компонентами:

Loader → Encoder → Indexer → Evaluator (опц.)

- **Loader** — загрузка аудио (soundfile / torchaudio / VAD + waveform);
- **Encoder** — извлечение эмбедингов (ONNX, ReDimNet, SpeechBrain, WeSpeaker и др.);
- **Indexer** — поиск соседей (FAISS Inner Product, AS-Norm);
- **Evaluator** — Precision@K по локальным меткам.

Все компоненты реализуют стандартные интерфейсы, конфигурируются через TOML, добавлена Docker-среда и прогресс-бар инференса.

5 Эксперименты с энкодерами

Ключевая гипотеза: качество энкодера — основной фактор, определяющий итоговую метрику. Были протестированы модели различных архитектур.

#	Энкодер	Аудио	P@10
1	baseline.onnx	случайные 6 с	0.0837
2	baseline.onnx	первые 6 с	0.0838
3	nvidia/titanet_large	первые 6 с	0.1968
4	speechbrain/ecapa-voxceleb	первые 6 с	0.5065
5	speechbrain/ecapa-voxceleb	полное аудио	0.5312
6	wespeaker/resnet293-LM	первые 6 с	0.5356
7	wespeaker/resnet34-LM	первые 6 с	0.5043
8	microsoft/wavlm-base-sv	первые 6 с	0.0547
9	microsoft/wavlm-base-plus-sv	первые 6 с	0.0976
10	IDRnD/redimnet_b6	первые 6 с	0.5840
11	damo/campplus_sv_zh-cn	первые 6 с	0.2774
12	iic/eres2netv2_sv_zh-cn	первые 6 с	0.2757
13	Стат. модель (на train)	первые 6 с	0.0115

5.1 Выводы по энкодерам

1. **ReDimNet-b6** — лучший результат (0.5840). Модель обучена на VoxCeleb2 с large-margin loss, выдаёт 192-мерные эмбединги.
2. **Полное аудио** лучше кропа: ECAPA-VoxCeleb показал +0.025 при подаче полного аудио vs первых 6 с.
3. **WavLM-модели** показали неожиданно плохие результаты (0.05–0.10) — вероятно, fine-tuning на speaker verification был недостаточным.
4. **Китайские модели** (CamPPlus, ERes2NetV2) показали средние результаты (≈ 0.28), что ожидаемо для моделей, обученных преимущественно на китайском языке.
5. **Статистическая модель**, обученная на фрагменте train, показала 0.0115 — подтверждает, что без глубокого обучения задача не решается.

6 Предобработка: Voice Activity Detection

6.1 Гипотеза

Тестовые записи содержат тишину, фоновые шумы и нецелевую речь. Удаление нецелевых сегментов через VAD должно улучшить качество эмбедингов.

6.2 FireRedVAD

Использовали FireRedVAD — модель голосовой активности, выдающую frame-level confidence scores (каждые 10 мс). Речевые сегменты конкатенируются и подаются в энкодер.

Энкодер	VAD	P@10	Δ
baseline.onnx	—	0.0838	—
baseline.onnx	FireRedVAD	0.0911	+0.007
redimnet_b6	—	0.5840	—
redimnet_b6	FireRedVAD	0.6074	+0.023

Вывод: VAD даёт стабильный прирост для обоих энкодеров. Для ReDimNet-b6 прирост +0.023 значителен и подтверждает, что удаление тишины и шума улучшает эмбединги.

7 Постобработка: Adaptive Score Normalization

7.1 Гипотеза

Cosine similarity между эмбедингами зависит не только от сходства голосов, но и от «сложности» записей. AS-Norm нормализует скоры относительно когорты — набора импостеров, что калибрует скоры и улучшает ранжирование.

7.2 Реализация AS-Norm

Используется подмножество эмбедингов из обучающего набора как когорта. Для каждой пары (query, candidate) скор нормализуется:

$$s_{\text{norm}}(q, c) = \frac{s(q, c) - \mu_q}{\sigma_q} + \frac{s(q, c) - \mu_c}{\sigma_c}$$

где μ_q, σ_q — среднее и стандартное отклонение скоров query относительно когорты.

Энкодер	Постобработка	P@10	Δ
baseline.onnx	—	0.0838	—
baseline.onnx	AS-Norm	0.0895	+0.006
redimnet_b6	—	0.5840	—
redimnet_b6	AS-Norm	0.6132	+0.029

Вывод: AS-Norm даёт значительный прирост (+0.029) для сильного энкодера. Это подтверждает, что нормализация скоров критична для задачи retrieval в реальных условиях.

8 Комбинация VAD + AS-Norm

Предобработка	Постобработка	P@10	Δ vs baseline
—	—	0.5840	—
FireRedVAD	—	0.6074	+0.023
—	AS-Norm	0.6132	+0.029
FireRedVAD	AS-Norm	0.6347	+0.051

Ключевой вывод: эффекты VAD и AS-Norm **аддитивны** — комбинация даёт +0.051, что близко к сумме индивидуальных приростов (+0.023 + +0.029 = +0.052). VAD улучшает *качество эмбедингов*, а AS-Norm улучшает *качество сравнения*.

8.1 Расширение пула кандидатов AS-Norm

В реализации AS-Norm параметр `faiss_candidates_coef` определяет, сколько кандидатов FAISS извлекает до ре-ранкинга нормализованными скорями:

$$\text{faiss_candidates} = K \times \text{faiss_candidates_coef}$$

При $K = 10$ и `coef=10` FAISS достаёт 100 кандидатов. Увеличение до `coef=100` (1 000 кандидатов) расширяет пул, из которого AS-Norm может «поднять» записи, имевшие низкий raw cosine, но высокий нормализованный скор.

Конфигурация	Коэф.	Кандидатов	P@10
Fine-tuned + VAD + AS-Norm	10	100	0.6568
Fine-tuned + VAD + AS-Norm	100	1 000	0.6632

Вывод: увеличение пула кандидатов с 100 до 1 000 даёт **+0.006**. Это подтверждает, что AS-Norm ре-ранкинг эффективно использует расширенный набор: некоторые записи того же спикера попадают в топ-10 только после нормализации.

9 Инженерные оптимизации

Суммарное время инференса с VAD + AS-Norm составляло $\approx 13\,300$ с (≈ 3.7 ч). Для ускорения были применены:

9.1 Префетч данных

`PrefetchDatasetLoader` оборачивает загрузчик и подгружает аудиофайлы в фоне через `ThreadPoolExecutor` с 8 воркерами. Скользящее окно из 8 `Future`-объектов: пока GPU обрабатывает текущий батч, следующие файлы уже читаются с диска.

9.2 Компиляция модели

```
torch.compile(model, backend="inductor mode="reduce-overhead")
```

- `backend="inductor"` — PyTorch 2.x backend, генерирует Triton/CUDA-код;
- `mode="reduce-overhead"` — CUDA graphs, минимизация Python overhead;
- Прогрев: 3 dummy forward pass до старта инференса;
- `torch.autocast(dtype=float16) + torch.no_grad()`.

Результат: время инференса сократилось с 13 310 с до **6 792 с** ($\approx 2 \times$ ускорение) при идентичном $P@10 = 0.6347$.

10 Fine-tuning ReDimNet-b6

10.1 Мотивация

ReDimNet-b6 предобучен на VoxCeleb2, а наши данные — подмножество VoxBlink2 (другой домен). Domain adaptation через fine-tuning должен улучшить представления для нашего конкретного распределения спикеров и условий записи.

10.2 Loss: AAM-Softmax (ArcFace)

Классификационная задача: по эмбедингу предсказать `speaker_id`. Angular margin отодвигает границу решения:

$$\mathcal{L} = -\log \frac{e^{s \cdot \cos(\theta_{y_i} + m)}}{e^{s \cdot \cos(\theta_{y_i} + m)} + \sum_{j \neq y_i} e^{s \cdot \cos \theta_j}}$$

где $s = 30$ — scale, m — margin (настраивается по стадиям).

10.3 3-стадийная стратегия

#	Стадия	Backbone	Opt	LR	Crop	Margin	Aug	Эпохи
1	Head warmup	frozen	SGD	0.1	3 с	0.0	да	3
2	Full finetune	unfrozen	AdamW	1e-4	4 с	0.2	да	7
3	Large margin	unfrozen	AdamW	1e-5	6 с	0.5	нет	5

Stage 1 (Head warmup): Backbone заморожен, обучается только AAM-Softmax head (11 053 классов $\times$ 192 dim). Margin=0 — чистый cosine softmax. Цель: инициализация головы.

Stage 2 (Full finetune): Backbone разморожен с $10\times$ меньшим LR чем head. Margin=0.2 — angular penalty. Более длинные кропы (4 с). Cosine scheduler.

Stage 3 (Large margin): Margin=0.5 — агрессивное разделение спикеров. 6 с кропы (приближение к инференсу). Без аугментаций — финальная доводка.

10.4 Аугментации (Stage 1–2)

- **Speed perturbation** (50%): скорость $0.9\times$ или $1.1\times$
- **Volume perturbation** (50%): случайный gain ± 6 dB
- **Time masking**: 0–5 сегментов по 10–30 мс зануляются
- **Additive Gaussian noise** (50%): SNR 5–25 dB

10.5 Инфраструктура обучения

- $2\times$ NVIDIA TESLA A16 (4×16 GB Ampere каждая, 64 GB на карту), DDP через Hugging-Face Accelerate

- Mixed precision (fp16)
- NCCL timeout: 24 ч (для стабильности при однопроцессной валидации)
- Чекпоинты сохраняются до валидации каждой эпохи и при улучшении val P@10

10.6 Промежуточные результаты обучения

Стадия	Эпоха	Loss	Acc	Val P@1	Val P@10	Время
1 (head warmup)	3/3	11.54	0.01%	0.426	0.068	—
2 (full finetune)	1/7	2.96	89.8%	0.484	0.076	11 642 с
2 (full finetune)	2/7	1.41	96.7%	0.490	0.077	11 643 с
2 (full finetune)	3/7	1.10	97.7%	0.494	0.077	11 641 с

Наблюдения:

- Loss стабильно падает: 11.54 → 2.96 → 1.41 → 1.10. Train accuracy растёт до 97.7%.
- Val P@1 монотонно растёт: 0.426 → 0.484 → 0.490 → 0.494, что подтверждает улучшение backbone на каждой эпохе.
- Val P@10 ограничен потолком ≈ 0.1 из-за малого числа файлов на спикера при `split_ratio=0` (6 733 файла ≈ 0.6 файлов/спикер), поэтому основным индикатором служит P@1.
- Каждая эпоха Stage 2 занимает ≈ 3.2 часа на наших мощностях ($2 \times$ NVIDIA TESLA A16) — обучение ограничено доступными вычислительными ресурсами команды.

10.7 Результаты на test_public

Чекпоинты после каждой эпохи Stage 2 тестировались на test_public в полном пайплайне (FireRedVAD + AS-Norm, `faiss_candidates_coef=100`):

Энкодер	Пайплайн	P@10	Δ vs pretrained
Pretrained ReDimNet-b6	VAD + AS-Norm	0.6347	—
Fine-tuned (Stage 2 ep.1)	VAD + AS-Norm	0.6632	+0.029
Fine-tuned (Stage 2 ep.2)	VAD + AS-Norm	0.6757	+0.041
Fine-tuned (Stage 2 ep.3)	чекпоинт получен, инференс не завершён (ограничение по времени)		

Выводы:

- Каждая эпоха fine-tuning даёт стабильный прирост: +0.029, затем ещё +0.013.
- Тренд не насыщен — модель продолжает улучшаться, что означает потенциал дальнейшего обучения.
- Чекпоинт epoch 3 получен, но инференс на полном тестовом наборе не успел завершиться до дедлайна. Именно этот чекпоинт загружен в репозиторий как финальное решение — ожидаемый результат выше 0.6757.

11 Итоговое решение

Финальный пайплайн:

1. **Загрузка:** torchaudio → mono 16 kHz
2. **VAD:** FireRedVAD — удаление тишины и шумовых сегментов
3. **Энкодер:** ReDimNet-b6 (fine-tuned) → 192-мерный L2-нормализованный эмбединг
4. **Оптимизации:** torch.compile + float16 + prefetch
5. **Поиск:** FAISS Inner Product с AS-Norm
6. **Выход:** submission.csv с 10 ближайшими соседями

Лучший подтверждённый результат на test_public: P@10 = **0.6757** (fine-tuned ReDimNet-b6, Stage 2 epoch 2, + FireRedVAD + AS-Norm с faiss_candidates_coef=100).

Финальный чекпоинт: Stage 2 epoch 3 загружен в репозиторий через Git LFS. По динамике обучения (монотонный рост P@1 на валидации и P@10 на test_public) ожидается результат выше 0.6757, но инференс на полном тесте не был завершён до дедлайна.

11.1 Сводная таблица прогресса

#	Конфигурация	P@10	Δ
1	Baseline организаторов	0.0837	—
2	ReDimNet-b6 (pretrained)	0.5840	+0.500
3	+ FireRedVAD	0.6074	+0.023
4	+ AS-Norm (coef=10)	0.6347	+0.027
5	+ Fine-tuning (Stage 2 ep.1) + AS-Norm coef=100	0.6632	+0.029
6	+ Fine-tuning (Stage 2 ep.2)	0.6757	+0.013
7	+ Fine-tuning (Stage 2 ep.3)	>0.6757	(ожд.)

Итого: от baseline 0.084 до лучшего подтверждённого 0.676 — улучшение в **8.1×**.

12 Выводы

1. **Выбор энкодера** — ключевой фактор: разница между baseline (0.084) и лучшим pretrained-энкодером (0.584) — 7×
2. **VAD + AS-Norm** — аддитивные эффекты: +0.023 и +0.029, в сумме +0.051.
3. **Fine-tuning** на целевых данных — второй по значимости фактор: 2 эпохи дали +0.041, и тренд не насыщен.
4. **Расширение пула кандидатов** AS-Norm (coef 10 → 100) дало +0.006 — дешёвое улучшение без дополнительного обучения.

5. **Инженерные оптимизации** (prefetch + torch.compile) дали $2\times$ ускорение без потери качества.
6. **WavLM-модели** (SSL-based) неожиданно проиграли supervised-моделям на данной задаче.
7. **Основное ограничение** — доступные вычислительные ресурсы команды: удалось пройти только 3 из 7 запланированных эпох Stage 2 и не начать Stage 3.

13 Дальнейшее развитие

Наш подход не исчерпал потенциал улучшений. При наличии дополнительного вычислительного бюджета следующие направления дали бы значительный прирост:

13.1 Завершение обучения

Наиболее очевидное улучшение. Текущая модель прошла лишь 3 из 7 эпох Stage 2 и не начала Stage 3 (large margin, $m = 0.5$, 6 с кропы). Динамика обучения (loss $11.5 \rightarrow 1.1$, P@10 $0.63 \rightarrow 0.68$ за 3 эпохи) показывает, что модель далека от насыщения. Полный цикл обучения (7 эпох Stage 2 + 5 эпох Stage 3) с высокой вероятностью дал бы P@10 > 0.75 .

13.2 Quality-aware scoring

Не все фреймы аудиозаписи одинаково информативны для идентификации спикера. Quality Measurement Function (QMF) оценивает качество каждого фрейма и взвешивает его вклад в итоговый эмбединг. Это особенно полезно для записей с переменным SNR — шумные сегменты получают меньший вес, а чистая речь — больший.

13.3 Multi-system fusion

Ансамбль нескольких архитектур энкодеров (ReDimNet + ResNet293-LM + ECAPA) на уровне скоров. Каждая архитектура захватывает разные аспекты голоса, и их комбинация снижает ошибки отдельных систем. На практике score-level fusion обычно даёт +5–10% относительного прироста.

13.4 Sub-center ArcFace

Замена стандартного AAM-Softmax на Sub-center ArcFace, где каждый класс (спикер) представлен несколькими центрами. Это позволяет моделировать intra-class вариации (один спикер в разных акустических условиях) без ослабления inter-class разделения.

13.5 Расширенные аугментации

- **MUSAN noise:** добавление реальных шумов (бабл, музыка, техногенный шум) вместо только гауссова;
- **RIR convolution:** свёртка с реальными импульсными характеристиками помещений для имитации реверберации;
- **Codec simulation:** пропускание аудио через кодеки (Opus, AMR-WB) для имитации телефонных искажений;
- **SpecAugment:** маскирование частотных и временных полос на мел-спектрограмме.

13.6 Embedding post-processing

Centering (вычитание глобального среднего), whitening (PCA), LDA — линейные преобразования пространства эмбеддингов, которые могут улучшить cosine similarity за счёт декорреляции признаков и выравнивания дисперсий.

14 Воспроизводимость

14.1 Зависимости

Python $\geq$ 3.10, torch $\geq$ 2.2, torchaudio $\geq$ 2.2, faiss-cpu/gpu, accelerate, scikit-learn, pandas, numpy, tqdm, soundfile. Полный список в `pyproject.toml`.

14.2 Модели

Модель	Источник	Лицензия
ReDimNet-b6	https://github.com/IDRnD/ReDimNet	Apache 2.0
FireRedVAD	https://github.com/FireRedTeam/FireRedVAD	Apache 2.0